

Generación de un modelo de Inteligencia Artificial para la segmentación de ecocardiogramas.

Andrés Alejandro Guzmán González^[A01633819], Ernesto Reynoso Lizárraga^[A01639915], Joel Isaias Solano Ocampo^[A01639289], and Tania Sayuri Guizado Hernandez^[A01640092]

Tecnológico de Monterrey, Campus Guadalajara, Av. General Ramón Corona 2514, Nuevo México, 45201 Zapopan, Jalisco, México

Resumen En este informe se presenta la estrategia para desarrollar dos modelos de inteligencia artificial: uno que realiza un análisis de visión computacional mediante un modelo UNET, y el otro que busca predecir puntos de referencia también denominados landmarks, para delimitar el perímetro del área de una imagen. Todo esto se lleva a cabo con la finalidad de segmentar el ventrículo izquierdo del corazón de manera automática en una máscara binaria, utilizando un conjunto de ecocardiogramas. Este conjunto de datos consta de 10,030 videos y fue obtenido del dataset Eco-Net Dynamic de la Universidad de Stanford [1].

Keywords: Inteligencia Artificial · Ecocardiograma · Modelo UNET · Ventrículo izquierdo · Máscaras · Landmark · Segmentación automática · Visión Computacional.

1. Introducción

Las cardiopatías son un tipo de enfermedad que afecta el corazón y los vasos sanguíneos. Cabe destacar que el riesgo de presentar una cardiopatía aumenta con el consumo de productos como el tabaco, tener una presión arterial alta, colesterol alto, una alimentación poco saludable, la falta de ejercicio y la obesidad, por mencionar algunos [2]. Según la Organización Mundial de la Salud, cada año mueren alrededor de 17.9 millones de personas en todo el mundo debido a algún padecimiento relacionado con complicaciones cardíacas [4].

Bajo esta premisa, este trabajo presenta dos enfoques para calcular el área del ventrículo izquierdo de diferentes ecocardiogramas con el fin de eficientar el proceso que toma al personal médico calcular el volumen de sangre que bombea el corazón en un intervalo de tiempo determinado. Para ello, los modelos de inteligencia artificial propuestos nos permiten generar una máscara binaria que corresponda al área dicha cavidad cardíaca.

Los modelos utilizados se estructuraron con redes neuronales convolucionales de tipo U-NET, un modelo dedicado a tareas de visión computacional. El primer modelo se utilizó para predecir la máscara del ventrículo izquierdo. El segundo modelo se empleó para predecir la probabilidad con respecto a la distribución de 7 landmarks para delimitar el área del ventrículo. Para ambos casos la entrada

de los modelos fueron fotogramas extraídos de los videos en el conjunto de datos. El objetivo es determinar cuál método es más efectivo para identificar la cavidad ventricular.

2. Análisis Exploratorio de Datos

Como primer proceso, se realizó un análisis exploratorio con el propósito de observar el comportamiento de los datos y poder detectar la presencia de datos faltantes o atípicos. Como se mencionó con anterioridad, el dataset [1] incluía un total de 10,030 videos, sin embargo, también contenía un archivo CSV con 6 columnas, cuyas descripciones generales se enlistan a continuación:

- **Filename:** Nombre del video archivo de video.
- **X1:** Valor de x del primer conjunto de pares ordenados (puntos).
- **Y1:** Valor de y del primer conjunto de pares ordenados (puntos).
- **X2:** Valor de x del segundo conjunto de pares ordenados (puntos).
- **Y2:** Valor de y del segundo conjunto de pares ordenados (puntos).
- **Frame:** Número de fotograma correspondiente a los conjuntos anteriores.

Cuadro 1: Ejemplos de los valores contenidos en el archivo CSV del Data Set para un único fotograma de uno de los videos. [1]

FileName	X1	Y1	X2	Y2	Frame
0X100009310A3BD7FC.avi	51.26041667	15.34895833	64.93229167	69.125	46
0X100009310A3BD7FC.avi	50.03761083	17.16784126	53.36722189	16.32132997	46
0X100009310A3BD7FC.avi	49.15737821	20.40762939	57.09054885	18.3907216	46
0X100009310A3BD7FC.avi	48.5381733	23.58105455	59.99733911	20.66770731	46
0X100009310A3BD7FC.avi	47.91896839	26.7544797	62.90412937	22.94469301	46
0X100009310A3BD7FC.avi	47.9621045	29.75951307	65.81091963	25.22167871	46
0X100009310A3BD7FC.avi	48.16791529	32.72318847	68.24704281	27.61832554	46
0X100009310A3BD7FC.avi	48.37372608	35.68686387	70.38531105	30.0906982	46
0X100009310A3BD7FC.avi	48.57953687	38.65053927	72.5235793	32.56307085	46
0X100009310A3BD7FC.avi	49.01403934	41.55607271	74.15164369	35.16515635	46
0X100009310A3BD7FC.avi	49.83099892	44.3643713	75.71299787	37.78420208	46
0X100009310A3BD7FC.avi	50.64795851	47.17266989	77.27435205	40.4032478	46
0X100009310A3BD7FC.avi	51.4649181	49.98096847	78.64469427	43.07085589	46
0X100009310A3BD7FC.avi	52.54732826	52.72177963	79.48537463	45.87312377	46
0X100009310A3BD7FC.avi	53.7042693	55.44364225	80.326055	48.67539165	46
0X100009310A3BD7FC.avi	54.36563	58.29149988	80.609375	51.61936132	46
0X100009310A3BD7FC.avi	51.15135239	62.12468928	80.609375	54.63536149	46
0X100009310A3BD7FC.avi	49.33671909	65.6020369	80.4312144	57.69665674	46
0X100009310A3BD7FC.avi	50.3482871	68.36085877	80.06545076	60.80564767	46
0X100009310A3BD7FC.avi	57.51297555	69.55532799	79.69968713	63.9146386	46
0X100009310A3BD7FC.avi	71.93835296	68.90385933	79.33392349	67.02362953	46

Respecto a la tabla anterior, cabe mencionar que por cada video se seleccionaron 2 fotogramas específicos, dando un total de 20,060 imágenes para entrenar los modelos. En cuanto a la representación gráfica de los pares ordenados, la documentación del dataset permitió identificar que los puntos constituían segmentos de recta, armando un esqueleto del área del ventrículo izquierdo, como se muestra en la figura uno.

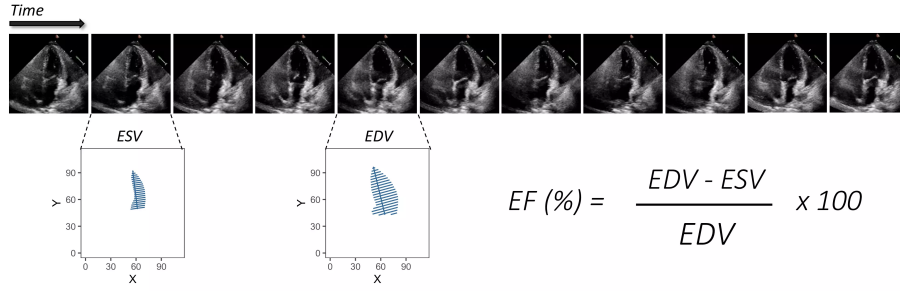


Figura 1: Ejemplificación del esqueleto formado en un par de fotogramas. [1].

Posteriormente, se realizó un gráfico de los puntos para generar una visión gráfica de su distribución en el plano cartesiano. Aunque en la figura número dos se muestran los resultados, se puede observar que los ventrículos están invertidos; esto se debe a la disposición del eje y para un fotograma de video cuyo valor máximo se encuentra en el origen del eje x.

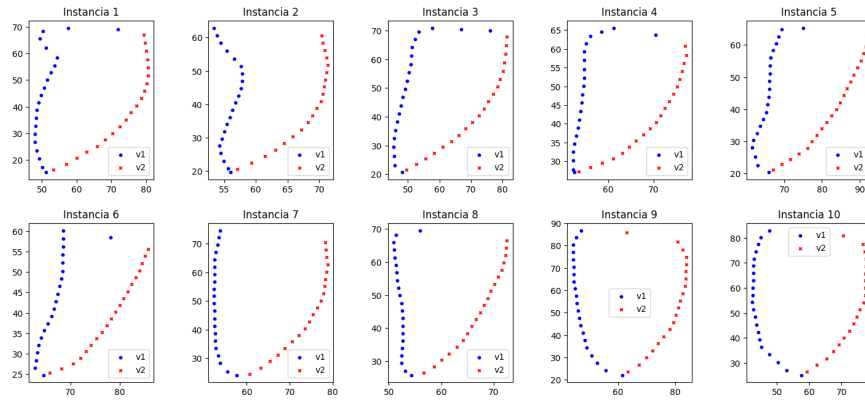


Figura 2: Gráficas con la distribución de puntos de 10 fotogramas seleccionados al azar.

Una vez analizada la información proporcionada por el conjunto de datos, se procedió a desarrollar una estrategia para almacenarla y facilitar su consulta a lo largo de todo el proceso de ejecución y pruebas. Esto llevó al equipo a estructurar una clase que pudiera almacenar el nombre del archivo de vídeo, los fotogramas seleccionados y arreglos que contienen los puntos de las fronteras del ventrículo izquierdo.

Una vez concluido este proceso, se avanzó en la generación de las máscaras. Sin embargo, se presentó un reto con el segmento de recta transversal del esqueleto, ya que la función para rellenar el área requería que los puntos estuvieran ordenados en el sentido de las manecillas del reloj. Esto llevó a la creación de un algoritmo que permitiera identificar esos puntos atípicos y reacomodarlos. Como resultado, se obtuvieron las máscaras binarias que conformarían el conjunto de validación para los entrenamientos de los modelos.




Figura 3: Máscaras binarias generadas para el conjunto de validación.

3. Metodología

3.1. Modelo de predicción de máscaras

Una vez generadas las instancias de la clase y las máscaras para validar las predicciones, se procedió a crear un modelo U-NET para iniciar los primeros entrenamientos y realizar las predicciones. Es relevante destacar que se empleó una red neuronal convolucional en los entrenamientos. Estas redes constan de tres tipos principales de capas:

- **Capas convolucionales:** Estas capas reducen el tamaño de las imágenes y, a través de filtros, ayudan a reconocer patrones simples, curvas y ejes en las imágenes.
- **Capas de agrupación máxima:** Estas capas agrupan los píxeles que tienen mayor importancia, generalmente aquellos más brillantes.
- **Capas de deconvolución:** Estas capas aumentan la resolución de la imagen para devolverla a su resolución original o incrementarla en el proceso.

Este tipo de modelos reciben como entrada un grid de números, que es la forma en que la computadora procesa imágenes. Comprender la estructura de las redes neuronales convolucionales permite entender lo que sucede internamente




Figura 4: Representación gráfica de una Red Neuronal Convolutional.

cuando se ejecutan los modelos para realizar diversas predicciones. Así mismo, es importante resaltar que el uso de un modelo U-net en este caso, se debe a que ha demostrado ser muy eficaz para el análisis de imágenes relacionadas con el sector salud.


4. Experimentos

4.1. Modelo de predicción de máscaras

En el proceso de validación y pruebas del primer modelo de predicciones, se tomó la decisión de evaluar su rendimiento utilizando un conjunto de datos extremadamente reducido, compuesto únicamente por 10 fotogramas. Es relevante subrayar que la primera red convolutional, objeto de este análisis, contaba con 5 capas de convolución. Durante las pruebas, se procedió a realizar cambios en las funciones de pérdida para evaluar su impacto en el desempeño del modelo.

Al realizar un análisis preliminar de los resultados obtenidos, se observó que, aunque la precisión (accuracy) era considerablemente alta, las máscaras resultantes presentaban deficiencias notables. Ante este panorama, se decidió llevar a cabo un aumento en la cantidad de datos utilizados para el entrenamiento, con la expectativa de mejorar el rendimiento del modelo. Si bien esta estrategia logró cierta mejora en las predicciones, se mantenía el objetivo de obtener un resultado más nítido y óptimo en términos de segmentación de imágenes.

Este escenario condujo a la construcción de un nuevo modelo, concebido para ser más robusto y entrenado con la mayor cantidad posible de imágenes. En nuevo modelo tuvo un total de 10 capas y al considerar que se seleccionaron 2 fotogramas de todo el conjunto de datos, la distribución de clases se organizó de la siguiente manera: 14,920 imágenes para entrenamiento, 2,552 para pruebas y 2,574 para validación, totalizando así 20,060 imágenes segmentadas. La estrategia implementada no solo proporcionó un resultado óptimo sino que también sentó las bases para el desarrollo del modelo de landmarks. En la figura 5 se muestra la máscara resultante de cada una de las pruebas realizadas.



(a) Predicción con modelo de 5 capas. (b) Predicción con modelo de 10 capas.

Figura 5: Máscaras binarias generadas con los modelos de prueba (a) y final (b).

4.2. Modelo de predicción de landmarks

Antes de abordar el proceso de experimentación de este modelo, es crucial destacar el concepto de landmark, que representa un punto de relevancia estratégicamente posicionado con un propósito específico. En este caso, los landmarks se implementaron con el fin de predecir el perímetro correspondiente al ventrículo izquierdo en los ecocardiogramas. Para lograrlo, fue necesario realizar un pre-procesamiento de las imágenes previamente seleccionadas, convirtiéndolas en un grid numérico o matriz para destacar los contornos de la máscara con los píxeles de la imagen, y posteriormente identificar los puntos de mayor relevancia para cerrar el perímetro ventricular.

La estrategia adoptada consistió en identificar 7 puntos distribuidos de la siguiente manera: uno en la posición más alta del área ventricular, 2 en las esquinas inferiores y 2 a cada lado de las paredes ventriculares. Una vez generado este mapeo, se procedió a crear un mapa de calor (heatmap) para visualizar la relevancia de estos puntos. Estos nuevos requerimientos desencadenaron un ajuste en el modelo, ya que su entrada pasó a ser la distribución de probabilidades gaussianas del contorno de la máscara ventricular y como salida se tendrían 7 canales, uno por cada punto a predecir. A diferencia del modelo anterior, que tenía una única salida binaria.

Considerados los ajustes se realizó una revisión de cómo se comportaban los landmarks. La figura 6 presenta los mapas de calor de una máscara de prueba, junto con una representación gráfica de la probabilidad gaussiana radial de los puntos y su distribución sobre el perímetro de la máscara.




Figura 6: Mapas de calor en el plano y sobre el perímetro ventricular.

Una vez validado que el algoritmo estaba identificando los landmarks de manera adecuada, se detonó el entrenamiento del modelo. Sin embargo, se encontró una limitación en la memoria disponible para realizar pruebas, lo que llevó a la decisión de reducir las capas del modelo con el objetivo de limitar el procesamiento necesario. Después de llevar a cabo diversas pruebas, se optó por un modelo de 5 capas, similar al utilizado en la primera etapa de pruebas del modelo anterior. A pesar de esta reducción, los resultados obtenidos fueron satisfactorios. La imagen número 7 muestra la comparación de un ecocardiograma seleccionado, el perímetro que se buscaba predecir y el resultado obtenido por el modelo. Este análisis visual permite evaluar la efectividad del modelo en la predicción precisa de los landmarks y, por ende, del perímetro ventricular en los ecocardiogramas.




Figura 7: Predicción del modelo final de landmarks.

Al concluir el proceso de experimentación, se seleccionó una estrategia para medir la precisión del modelo. Para ello, se utilizó la función Structural Similarity (SSIM) con el propósito de comparar el área predicha por los modelos con el área real definida en las máscaras de validación. Esta función aplica un filtro a la máscara predicha y la compara con la máscara real, proporcionando un porcentaje de similitud como resultado. En la Tabla 2 se presentan los porcentajes de similitud obtenidos por los modelos, ofreciendo una métrica cuantitativa para evaluar la calidad de las predicciones.

Modelo	Porcentaje de similitud
Máscaras	90.54
Landmarks	85.31

Cuadro 2: Resultados de similitud

Después de entrenar los modelos, se llevaron a cabo evaluaciones mediante 15 predicciones utilizando imágenes externas al conjunto de datos de prueba. El objetivo era analizar el comportamiento del modelo frente a ecocardiogramas que presentaran más ruido o no fueran tan nítidos como las imágenes utilizadas durante el entrenamiento. Sorprendentemente, y en contraste con los resultados

anteriores, se observó que el modelo de landmarks mostró una eficiencia superior para este conjunto de imágenes externas, como se ilustra en la figura número 8. Este hallazgo resalta la capacidad del modelo para generalizar su desempeño a datos más diversos y ruidosos.




Figura 8: Predicciones obtenidas. Máscaras(a) Landmarks (b).

5. Resultados

Al concluir todo el proceso de experimentación, se tomó la decisión de presentar de manera gráfica la distribución de resultados de similitud de ambos modelos. Aunque se proporcionó un resultado numérico anteriormente, es relevante identificar la distribución de la similitud en todo el segmento de prueba. En la figura siguiente, se muestran los histogramas tanto para el modelo de máscaras como para el modelo de landmarks.





Figura 9: Predicciones obtenidas con imágenes del conjunto de prueba. Máscaras(a) Landmarks (b).

A pesar de que ambos modelos arrojaron resultados muy buenos, se puede observar que el modelo de máscaras tuvo un desempeño ligeramente superior en el conjunto de datos original. No obstante, el proceso de experimentación dejó

en claro que el modelo de máscaras destaca en comparación por la nitidez de los ecocardiogramas analizados. Por esta razón, se considera esencial presentar también los histogramas de similitud obtenidos en la fase de pruebas que involucró imágenes externas a los conjuntos de prueba.



(a) Histogramas de resultados del conjunto de imágenes de prueba del data-set. (b) Histograma de resultados de prueba (landmarks).

Figura 10: Histogramas de resultados del conjunto de imágenes externo al data-set.

Nuevamente, se observa que el modelo de máscaras mostró un porcentaje de similitud más alto en este conjunto de pruebas. Sin embargo, es importante señalar que los resultados visuales fueron significativamente mejores con el modelo de landmarks y dada la naturaleza del problema se priorizan los resultados visuales que los numéricos. Esta disparidad tiene su origen en la limitada cantidad de imágenes utilizadas para este proceso. Para futuras mejoras, se ha identificado el considerar la inclusión de imágenes con menos nitidez en el conjunto de entrenamiento para que el modelo adquiriera la capacidad de identificar la cavidad ventricular izquierda incluso en imágenes con más ruido.

6. Conclusiones

Los resultados obtenidos en este trabajo lograron generar y comparar dos modelos de inteligencia artificial diseñados para segmentar el ventrículo izquierdo del corazón a partir de imágenes de ecocardiogramas. Este proyecto resultó de vital importancia, no solo para establecer los conceptos fundamentales de las estructuras de modelos de redes neuronales convolucionales, su funcionamiento y los fundamentos matemáticos que permiten comprender su operación, sino también como un medio para entender la aplicabilidad de la inteligencia artificial en campos como la medicina.

Además de los aspectos técnicos, este proyecto abordó de manera consciente la ética vinculada al uso y manejo de datos sensibles. Pues implica el uso de imágenes que representan las condiciones de salud de muchas personas, destacando la importancia de ser conscientes de la relevancia del análisis de datos en

la actualidad. Es fundamental aprender a utilizar información de acceso público, cumplir con los lineamientos establecidos por las instituciones que facilitan el acceso a estos datos, y comprender la importancia de que estos estén anonimizados para su uso y análisis. Este enfoque ético es esencial en el desarrollo de proyectos de inteligencia artificial en todos los ámbitos.

Finalmente, se aplicaron conceptos como el uso de cómputo en la nube, que se convirtió en el medio para almacenar las diversas imágenes generadas por el modelo y los datos de entrenamiento, prueba y validación. Esto garantizó que los miembros del equipo tuvieran acceso a ellas para realizar pruebas de manera remota. Además, se destacó la importancia del uso de conocimientos estadísticos para evaluar el rendimiento del modelo. La combinación de estos elementos permitió poner en práctica y consolidar los diversos contenidos aprendidos en clase, abarcando desde el manejo de datos hasta la construcción y evaluación efectiva de modelos de inteligencia artificial.

7. Conclusiones Individuales

Andrés Alejandro Guzmán González

Con el desarrollo de este trabajo, tuve la oportunidad de aplicar los conocimientos adquiridos en clase, comprendiendo a fondo cómo la inteligencia artificial puede ser una herramienta transformadora en diversos aspectos de la vida cotidiana, especialmente en la optimización de procesos. En particular, encuentro muy enriquecedora la situación problema que va de automatizar el proceso de segmentación del ventrículo izquierdo mediante la implementación de modelos de inteligencia artificial y visión computacional. Así mismo, la aplicación de conceptos estadísticos para la evaluación de los rendimientos de un modelo de inteligencia artificial, estrategias de administración, almacenamiento y control de grandes cantidades de datos (Big Data), y la aplicación de estrategias de almacenamiento en la nube para eficientar procesos de consulta de información y/o datos.

Este proyecto me ha proporcionado una visión más clara sobre cómo la tecnología puede ser un medio para mejorar significativamente la calidad de vida de las personas. Pero también sobre la importancia de tener presente la ética con el manejo de datos, este reto presentaba el uso de imágenes sensibles y confidenciales que podrían reflejar el estado de salud de muchas personas, es por ello que ser conscientes de las diferentes normativas para el uso de datos es indispensable para el desarrollo de cualquier proyecto tecnológico no solo los de inteligencia artificial. Considero que este proyecto fue tanto retador como fascinante, ya que me permitió explorar la estructuración de diferentes modelos de inteligencia artificial y conocer diversas estrategias que actualmente la industria aplica para contribuir positivamente a la sociedad. Este proceso no solo ha mejorado mi dominio práctico de los conceptos de la concentración; también ha detonado mi interés por seguir explorando aplicaciones de la inteligencia artificial para resolver problemas cotidianos.

Ernesto Reynoso Lizárraga

A lo largo de este proyecto aprendí varias acerca de los modelos de inteligencia artificial y también sobre las problemáticas que se enfrenta la industria hoy en día y que se busca resolver con dichos modelos. Con los resultados de nuestro modelo puedo concluir que realizar un modelo de inteligencia artificial no es fácil y hay muchos factores a tener en cuenta, tales como los datos con los que vas a trabajar, los hiperparámetros, la efectividad, el tiempo de ejecución, hasta otros factores no propios del modelo como el equipo con el que estas trabajando. También cabe mencionar que no existe una forma de hacer el modelo ideal más allá de la aproximación y la prueba y error, y que como observamos en los resultados, el modelo puede resolver eficientemente el problema si lo ajustas al conjunto de datos con el que trabajas, pero puede no ser lo ideal cuando se intenta predecir imágenes de un conjunto de datos distinto. Para finalizar quiero decir que se debe de ser muy consciente y responsable sobre los datos con los que se están trabajando ya que dichos datos, aunque estén destinados para la experimentación y el estudio, siguen siendo datos reales de personas, por lo que se debe de tener cierto criterio al trabajar con ellos.

Joel Isaias Solano Ocampo

La solución reto a conllevar durante estos dos bloques de desarrollo en segunda mitad de la concentración de Inteligencia artificial avanzada para la ciencia de datos fue más que solo retadora. Estuvo llena de obstáculos, llena de incógnitas y sobre todo, mucho aprendizaje de por medio. Como equipo, siento que llegamos a tener muchas dificultades en determinados procesos técnicos al momento de tratar de implementar ciertas soluciones algorítmicas o de complejidad tanto de hardware como de software lo que llegó a detener en determinados momentos el flujo constante que solíamos tener de trabajo. De aquí puede también mencionar que se deriva de muchas dudas respecto a qué soluciones podríamos tratar de aproximarnos para solventar dichos obstáculos, cuales podrían ser las mas efectivas, como llegaron dichas soluciones a impactar en toda la implementación y si dicha solución no sería solo el generador de mayores dificultades que remedios para el objetivo deseado. Algo que definitivamente nos terminó marcando como equipo, individuos y compañeros fueron los aprendizajes que obtuvimos durante la implementación del reto, ya que estábamos adentrándonos en una rama de conocimiento de nuestra carrera que es nueva y compleja para todos nosotros. Además, se trató de una concentración cuyo objetivo es precisamente buscar un tipo de especialización en el área para que más adelante nos podamos seguir especializando en el área una vez concluya la misma e inclusive una vez terminemos la carrera profesional y decidimos adentrarnos en el tema ya sea por medio de la industria, la investigación o algún otro medio posible en donde podamos ver reflejado nuestro trabajo. Para terminar de hablar, me gustaría decir que me termino agradando mucho lo que se terminó logrando con este reto de tan gran impacto, me sorprendió mucho cómo a pesar de seguir siendo estudiantes de universidad y de ser esta nuestra primera aproximación a la materia, tuvimos

la oportunidad de mostrar nuestros resultados a una empresa de reconocimiento y pronombre mundial en el área de la inteligencia artificial. Me termino llevando de este reto y de esta concentración las ganas de seguir aprendiendo de este campo tan amplio que es la inteligencia artificial para seguir desarrollándome de manera profesional y así alcanzar objetivos que si bien, aún no me he podido plantear aun, se que se aproximarán eventualmente.

Tania Sayuri Guizado Hernandez

En desarrollo de este proyecto, a partir de nuestro dataset EchoNet-Dynamic Cardiac Ultrasound, el equipo fue capaz de emplear habilidades técnicas para el procesamiento de imágenes, aplicación de algoritmos de aprendizaje profundo, así como también una comprensión sólida de la ética en la investigación médica y el cumplimiento normativo. Quisiera resaltar especialmente que nos propusimos investigar cómo nuestro conjunto de datos establece de manera clara en sus condiciones de uso la restricción de distribución y la garantía de que su utilización esté destinada exclusivamente a fines de investigación no comerciales. Asimismo, en lo que respecta a la anonimización, reconocemos que la integridad y privacidad de los datos se preservan conforme a lo estipulado en su página oficial. Esta información desempeñó un papel esencial en nuestro proyecto porque atribuyó a respaldar la transparencia y la trazabilidad en la gestión de datos sensibles. Por otro lado, en la aplicación de modelos U-Net obtuvimos una nueva perspectiva, porque durante el proceso fuimos descubriendo la necesidad e importancia de no solo familiarizarse con arquitecturas de redes neuronales y dominio de técnicas de aprendizaje profundo, sino el también de cultivar una apreciación crítica de los principios médicos subyacentes. Al enfrentarnos a desafíos significativos y una complejidad inherente en la obtención de máscaras precisas del ventrículo izquierdo, así como los posibles rangos para asignar a una landmark, en la superación de estas complejidades mediante una integración eficaz de avanzadas técnicas de aprendizaje profundo, aspiramos a entender que esta implementación no solo facilitará una segmentación más precisa, sino que también contribuirá de manera sustancial a una interpretación más refinada de las imágenes cardíacas en un escenario real del ámbito médico a lo que atribuirá en diagnosticos y tratamientos eficientes. Con esta valiosa experiencia, logré observar cómo la sinergia entre la tecnología de vanguardia y la medicina demuestra que la aplicación efectiva de modelos de aprendizaje profundo puede generar un impacto notable en la mejora de la atención médica, y quizá en cualquier campo diferente al ámbito medicinal.

Referencias

1. EchoNet-Dynamic.(2020). *Stanford University*. Disponible en: <https://echonet.github.io/dynamic/>. Accedido en Septiembre de 2023.
2. Definición de cardiopatía. (s.f.). *Instituto Nacional del cancer*. Disponible en: <https://www.cancer.gov/publications/dictionaries/cancer-terms/def/heart-disease>. Accedido en noviembre de 2023.
3. EchoNet-Dynamic.[imagen] (2020). *Stanford University*. Disponible en: <https://echonet.github.io/dynamic/>. Accedido en Septiembre de 2023.
4. Enfermedades cardiovasculares. (s.f.). *Organización Mundial de la Salud*. Disponible en: <https://www.who.int/es/health-topics/cardiovascular-diseases#tab=tab1>. Accedido en noviembre de 2023.